

Laporan Kemajuan Proyek Data Warehouse

S1 Sains Data, Fakultas Matematika Ilmu Pengetahuan dan IPA
Universitas Negeri Surabaya

Kelas	2024-D
Ketua	Santi Laelatul Mu'azaroh (24031554004)
Anggota 1	Christine Aprilia Putri (24031554046)
Anggota 2	-
URL Github	https://github.com/christine2646/UAS_DWH_KELOMPOK-6

Informasi Umum Proyek

Judul	Optimasi ETL Pipeline pada Data Warehouse untuk Analisis HIV/AIDS dan Kesehatan Reproduksi Global Berbasis OLAP
Topik	Sosial/Kesehatan
Revisi?	Ya / Tidak

Deskripsi Rumusan masalah	Kesehatan global merupakan salah satu aspek penting yang perlu dipantau secara berkala, terutama terkait penyebaran HIV/AIDS dan kondisi kesehatan reproduksi pada berbagai negara. Informasi kesehatan tersebut digunakan sebagai pendukung evaluasi dan pengambilan kebijakan kesehatan di tingkat internasional. Namun, banyaknya jumlah negara, indikator kesehatan, dan periode waktu menyebabkan proses pengolahan data menjadi cukup kompleks. Permasalahan utama terletak pada sulitnya melakukan integrasi dan analisis data kesehatan global secara cepat dan terstruktur. Dataset kesehatan memiliki karakteristik multidimensi, time-series, serta mengandung missing value dan format data yang belum seragam. Kondisi tersebut menyebabkan proses analisis manual menjadi kurang efisien, terutama ketika ingin melakukan perbandingan antar negara maupun analisis perkembangan indikator kesehatan dari tahun ke tahun. Selain itu, proses eksplorasi data kesehatan global membutuhkan mekanisme analisis yang mampu mendukung query multidimensi dan agregasi data dalam jumlah besar. Tantangan lainnya adalah bagaimana melakukan transformasi data mentah menjadi struktur yang sesuai untuk kebutuhan OLAP sehingga insight dapat diperoleh dengan lebih mudah dan interaktif. Maka dari itu, diperlukan penerapan Data Warehouse dengan proses ETL dan OLAP untuk mengintegrasikan, menyimpan, serta menyajikan data kesehatan global secara lebih terorganisasi dan optimal.
Target insight yang ingin dicapai	Insight yang ingin diperoleh melalui proses Data Staging dan Data Presentation menggunakan mekanisme CUBE query yaitu : 1. Mengetahui tren perkembangan HIV/AIDS global pada periode 2020-2024 2. Menganalisis perkembangan indikator kesehatan reproduksi di berbagai negara 3. Membandingkan kondisi kesehatan antar negara berdasarkan indikator kesehatan tertentu 4. Mengidentifikasi negara yang mengalami peningkatan atau penurunan signifikan pada indikator HIV/AIDS maupun kesehatan reproduksi 5. Melakukan analisis multidimensi berdasarkan dimensi waktu, negara, dan indikator kesehatan

	6. Menampilkan hasil analisis dalam bentuk visualisasi OLAP interaktif menggunakan Atoti.
Referensi penelitian	[Jika ada perubahan] Tuliskan 3-5 penelitian terdahulu yang menjadi inspirasi pengerjaan proyek Anda. Penelitian terdahulu wajib: jurnal internasional dengan penerbit selain MDPI. Jurnal terbit setidaknya di tahun 2020. Tuliskan <u>link-link DOI-nya</u> saja cukup.

Informasi Detil Dataset

Sumber dataset	Dataset yang digunakan berasal dari World Bank Health Nutrition and Population Statistics yang diakses melalui: World Bank Health Nutrition and Population Statistics Proses akuisisi data dilakukan dengan memilih seluruh negara yang tersedia, indikator pada kategori HIV/AIDS dan reproductive health, serta rentang waktu tahun 2020–2024. Dataset diunduh dalam format Excel (.xlsx) dan CSV untuk mendukung proses eksplorasi data, ETL, integrasi metadata, dan pembangunan Data Warehouse. Selain dataset utama, kami memanfaatkan World Bank Country API untuk memperoleh metadata tambahan terkait region dan income group negara yang digunakan pada dimensi geografis (dim_country). API yang digunakan: World Bank Country API
Deskripsi umum dataset / datadump	Dataset berisi berbagai indikator kesehatan global yang berkaitan dengan HIV/AIDS dan kesehatan reproduksi dari berbagai negara di dunia. Data utama pada Data memiliki atribut berupa Series Name, Series Code, Country Name, Country Code, serta data tahunan dari tahun 2020 hingga 2024. Selain itu, dataset juga dilengkapi dengan Metadata yang berisi informasi tambahan terkait indikator kesehatan seperti Indicator Name, Source, Topic, Aggregation Method, dan Periodicity. Metadata tersebut digunakan untuk membantu proses identifikasi dan integrasi indikator pada pembangunan Data Warehouse. Dataset memiliki struktur time-series karena memuat data tahunan selama periode 2020–2024 serta bersifat multidimensi karena mencakup banyak negara dan indikator kesehatan.
Aspek khusus dari dataset	Berdasarkan hasil observasi awal, dataset memiliki ukuran sebesar 14.901 baris dan 9 kolom. Hasil analisis menunjukkan bahwa dataset memiliki tingkat sparsity yang cukup tinggi (40.19%) karena banyaknya missing value pada beberapa indikator kesehatan dan negara tertentu, terutama pada tahun terbaru. Missing value direpresentasikan dalam bentuk simbol “..” dan kemudian dikonversi menjadi NaN pada tahap preprocessing. Selain itu, distribusi data antar indikator kesehatan juga tidak merata. Statistik deskriptif menunjukkan perbedaan yang cukup besar antara median dan nilai maksimum sehingga distribusi data bersifat right-skewed. Visualisasi boxplot juga menunjukkan adanya outlier pada beberapa indikator kesehatan dengan nilai yang jauh lebih tinggi dibanding data lainnya. Outlier tersebut berasal dari negara dengan jumlah populasi, kasus HIV/AIDS, atau indikator kesehatan tertentu yang sangat tinggi dibanding negara lain. Dataset masih berbentuk wide format dengan kolom tahunan terpisah sehingga memerlukan transformasi menjadi long format untuk mendukung proses ETL, dimensional modeling, dan analisis OLAP multidimensi..

Kemajuan Pengerjaan Data Staging

Tahap ekstraksi	Tahap ekstraksi dilakukan menggunakan Python pada Jupyter Notebook dengan library utama pandas untuk membaca dataset kesehatan global dari World Bank Health Nutrition and Population Statistics. Dataset diperoleh melalui proses unduh manual dari portal World Bank dengan memilih seluruh negara yang tersedia, indikator pada kategori HIV/AIDS dan reproductive health, serta rentang waktu
-----------------	--

	tahun 2020–2024. Pada proses ETL, data utama dibaca menggunakan file Excel (.xlsx) karena memiliki struktur dataset dan metadata yang lebih terorganisasi dalam beberapa sheet sehingga lebih mudah digunakan pada proses eksplorasi dan transformasi data. Proses ekstraksi dilakukan menggunakan fungsi <code>pd.read_excel()</code> untuk membaca sheet Data dan Series - Metadata. Sheet Data digunakan sebagai sumber utama indikator kesehatan global yang berisi atribut seperti Series Name, Series Code, Country Name, Country Code, serta data tahunan 2020–2024. Sementara itu, sheet Series - Metadata digunakan untuk memperoleh informasi tambahan terkait indikator kesehatan seperti Indicator Name, Topic, Source, Aggregation Method, Periodicity, dan definisi indikator kesehatan lainnya yang akan dimanfaatkan dalam pembentukan dimension table pada Data Warehouse. Selain dataset utama, kami juga memanfaatkan World Bank Country API untuk memperoleh metadata tambahan berupa region dan income group negara yang digunakan pada dimensi geografis (<code>dim_country</code>). Tahap ekstraksi juga mencakup identifikasi struktur dataset, pengecekan jumlah data, validasi atribut, serta observasi awal data sebelum memasuki tahap preprocessing dan transformasi data lebih lanjut.
Tahap transformasi	Tahap transformasi dilakukan untuk membersihkan dan menyeragamkan data agar sesuai dengan kebutuhan Data Warehouse dan OLAP. Proses transformasi mencakup penanganan missing value, konversi tipe data numerik., validasi dan pengecekan data duplikat., transformasi wide format menjadi long format menggunakan <code>melt/unpivot</code>, integrasi dataset utama dengan metadata indikator kesehatan, selain itu, dilakukan penambahan metadata region dan income group negara menggunakan World Bank Country API sebagai enrichment pada dimensi geografis (<code>dim_country</code>). Setelah proses integrasi selesai, data dipisahkan ke dalam struktur star schema yang terdiri dari <code>fact_health</code>, <code>dim_country</code>, <code>dim_indicator</code>, dan <code>dim_time</code>. Pada tahap ini juga dilakukan pembentukan surrogate key yang digunakan sebagai primary key pada setiap tabel dimensi dan fact table untuk mendukung efisiensi relasi dan query OLAP.
Tahap load	Tahap load dilakukan dengan memuat hasil transformasi data ke PostgreSQL sebagai repositori utama Data Warehouse menggunakan SQLAlchemy dan psycopg2. Data hasil ETL dipisahkan ke dalam struktur star schema yang terdiri dari <code>fact_health</code>, <code>dim_country</code>, <code>dim_indicator</code>, <code>dim_time</code>. Sebelum dimuat ke PostgreSQL, setiap tabel disimpan dalam format CSV sebagai arsip data staging dan hasil transformasi ETL. Selanjutnya, proses loading dilakukan menggunakan fungsi <code>to_sql()</code> dari pandas untuk memasukkan seluruh fact table dan dimension table ke PostgreSQL. Pada tahap ini juga dilakukan pembentukan primary key berbasis surrogate key untuk mendukung relasi antar tabel dan efisiensi query OLAP. Ukuran database yang telah diperoleh terdiri dari satu fact table dan tiga dimension table. Setelah dilakukan transformasi dari wide format ke long format menggunakan <code>melt/unpivot</code>, jumlah data meningkat menjadi sekitar 74.505 record karena setiap indikator direpresentasikan berdasarkan kombinasi negara, indikator, dan tahun sehingga database bisa mendukung kebutuhan analisis multidimensi dan time-series. Teknologi PostgreSQL yang telah digunakan pada tahap awal mencakup ; - PostgreSQL (relational database) - SQLAlchemy - psycopg2 Performance benchmarking pada tahap ini masih dilakukan secara sederhana melalui pengujian keberhasilan loading data dan eksekusi query dasar pada PostgreSQL. Pengujian dilakukan dengan memastikan seluruh tabel berhasil dimuat, relasi antar tabel dapat digunakan dengan baik, serta query SELECT dapat dijalankan tanpa kendala. Hasil pengujian menunjukkan bahwa PostgreSQL mampu menangani proses loading dan query dasar Data Warehouse dengan baik sehingga struktur database telah siap digunakan pada tahap OLAP dan visualisasi menggunakan Atoti.

Kemajuan Pengerjaan Data Presentation

Subject focus	Proses OLAP difokuskan pada analisis multidimensi data kesehatan global yang berkaitan dengan HIV/AIDS dan kesehatan reproduksi berdasarkan dimensi waktu, negara, dan indikator kesehatan. Analisis dilakukan menggunakan data hasil ETL yang telah dimuat ke dalam Data Warehouse berbasis PostgreSQL dengan struktur star schema. Fokus utama analisis OLAP meliputi: 1. Analisis tren perkembangan indikator HIV/AIDS global pada periode 2020–2024. 2. Analisis perkembangan indikator kesehatan reproduksi pada berbagai negara. 3. Perbandingan kondisi kesehatan antar negara berdasarkan indikator kesehatan tertentu. 4. Identifikasi negara dengan peningkatan atau penurunan signifikan pada indikator kesehatan. 5. Analisis multidimensi berdasarkan kombinasi dimensi waktu, negara, dan indikator kesehatan menggunakan query agregasi dan ROLLUP. Melalui proses OLAP, data kesehatan global dapat dianalisis secara lebih cepat, terstruktur, dan fleksibel untuk mendukung eksplorasi insight berbasis data.																				
Star schema	Struktur Data Warehouse menggunakan model star schema yang terdiri dari satu fact table dan tiga dimension table. Struktur tersebut dirancang untuk mendukung proses OLAP dan analisis multidimensi berdasarkan dimensi waktu, negara, dan indikator kesehatan. Dengan penerapan star schema, proses query agregasi dan eksplorasi data dapat dilakukan dengan lebih efisien karena seluruh dimension table terhubung langsung ke fact table sebagai pusat penyimpanan data utama. Berikut tabel yang digunakan dalam pembentukan star schema: <i>Tabel 1. Daftar Tabel Star Schema</i> <table><tr><th>Tabel</th><th>Jenis Tabel</th><th>Fungsi dalam OLAP</th><th>Hierarchy/Measures</th></tr><tr><td>fact_health</td><td>Fact Table</td><td>Menyimpan data utama indikator kesehatan global</td><td>Measures: health_value</td></tr><tr><td>dim_country</td><td>Dimension Table</td><td>Analisis geografis berdasarkan negara dan region</td><td>Hierarchy: Region -> Country</td></tr><tr><td>dim_indicator</td><td>Dimension Table</td><td>Analisis jenis indikator kesehatan</td><td>Dimension: indikator kesehatan</td></tr><tr><td>dim_time</td><td>Dimension Table</td><td>Analisis tren waktu dan time-series</td><td>Hierarchy: Year</td></tr></table> 1. fact_health Tabel fact_health berada di pusat skema dan berfungsi sebagai tempat penyimpanan utama nilai transaksi atau kejadian kuantitatif yang diukur secara berkala. Tabel ini juga mengikat seluruh tabel dimensi melalui relasi Foreign Key (FK). Kolom health_value bertindak sebagai Measure (Metrik utama). Kolom ini bertipe data numerik kontinu (seperti angka kasus atau persentase cakupan) yang menjadi bahan dasar operasi agregasi seperti	Tabel	Jenis Tabel	Fungsi dalam OLAP	Hierarchy/Measures	fact_health	Fact Table	Menyimpan data utama indikator kesehatan global	Measures: health_value	dim_country	Dimension Table	Analisis geografis berdasarkan negara dan region	Hierarchy: Region -> Country	dim_indicator	Dimension Table	Analisis jenis indikator kesehatan	Dimension: indikator kesehatan	dim_time	Dimension Table	Analisis tren waktu dan time-series	Hierarchy: Year
Tabel	Jenis Tabel	Fungsi dalam OLAP	Hierarchy/Measures																		
fact_health	Fact Table	Menyimpan data utama indikator kesehatan global	Measures: health_value																		
dim_country	Dimension Table	Analisis geografis berdasarkan negara dan region	Hierarchy: Region -> Country																		
dim_indicator	Dimension Table	Analisis jenis indikator kesehatan	Dimension: indikator kesehatan																		
dim_time	Dimension Table	Analisis tren waktu dan time-series	Hierarchy: Year																		

	rata-rata (AVG), total (SUM), maupun perhitungan nilai minimum/maksimum. 2. <i>dim_country</i> Tabel <i>dim_country</i> menyediakan konteks geopolitik dan sosio-ekonomi untuk menjawab pertanyaan di mana peristiwa atau angka kesehatan tersebut tercatat. Tabel ini mendukung fitur analisis Drill-Down (melihat data lebih rinci) dan Roll-Up (merangkum data ke tingkat atas) dengan struktur hierarki dua tingkat. 3. <i>dim_indicator</i> Tabel <i>dim_indicator</i> digunakan untuk melakukan analisis jenis indikator kesehatan. Dimensi ini bertugas memberikan konteks "Apa" yang sedang diukur pada nilai tabel fakta, sehingga angka pada variabel <i>health_value</i> memiliki makna medis atau publik (misalnya membedakan kasus HIV/AIDS atau cakupan kesehatan reproduksi). 4. <i>dim_time</i> Tabel <i>dim_time</i> Digunakan untuk melakukan analisis tren waktu dan runtun waktu (time-series). Dimensi ini bertugas menjawab pertanyaan "Kapan" data kesehatan tersebut dicatat, memungkinkan pengguna melihat progres atau penurunan indikator dari waktu ke waktu. Memiliki struktur hierarki berbasis Year (Tahun) untuk melihat dinamika dan fluktuasi data kesehatan dalam basis tahunan.
Hasil OLAP	Hasil sementara proses OLAP menunjukkan bahwa struktur Data Warehouse yang telah dibangun mampu mendukung analisis multidimensi berdasarkan dimensi waktu, negara, dan indikator kesehatan. Proses analisis dilakukan menggunakan query agregasi pada PostgreSQL dengan memanfaatkan struktur star schema yang terdiri dari fact table dan dimension table. Pada tahap ini, query OLAP dilakukan menggunakan operasi agregasi seperti GROUP BY dan ROLL UP untuk menghasilkan ringkasan data kesehatan global berdasarkan kombinasi dimensi tertentu. Hasil query menunjukkan bahwa terdapat variasi nilai indikator kesehatan antar negara dan antar periode waktu. Selain itu, beberapa indikator HIV/AIDS dan kesehatan reproduksi menunjukkan pola perubahan yang berbeda pada setiap region dan negara. Analisis time-series pada periode 2020–2024 menunjukkan adanya perubahan tren pada beberapa indikator kesehatan global. Beberapa negara mengalami peningkatan nilai indikator kesehatan reproduksi, sementara negara lain menunjukkan penurunan atau fluktuasi pada indikator HIV/AIDS. Hasil agregasi juga menunjukkan bahwa distribusi data antar negara tidak merata sehingga beberapa negara memiliki nilai indikator yang jauh lebih tinggi dibandingkan negara lain. Selain analisis berdasarkan waktu, proses OLAP juga digunakan untuk melakukan perbandingan antar negara menggunakan agregasi multidimensi. Query ROLL UP memungkinkan sistem menghasilkan ringkasan data secara hierarkis sehingga proses analisis total maupun subtotal berdasarkan kombinasi dimensi dapat dilakukan dengan lebih efisien.
Visualisasi OLAP	Visualisasi OLAP sementara dilakukan menggunakan library visualisasi Python seperti Matplotlib dan Seaborn berdasarkan hasil query agregasi dari PostgreSQL. Visualisasi digunakan untuk membantu proses interpretasi data kesehatan global sehingga pola, tren, dan perbandingan antar negara dapat diamati dengan lebih mudah.