

Proposal Proyek Data Warehouse

S1 Sains Data, Fakultas Matematika Ilmu Pengetahuan dan IPA
Universitas Negeri Surabaya

Kelas	2024-D
Ketua	Santi Laelatul Mu'azaroh (24031554004)
Anggota 1	Christine Aprilia Putri (24031554046)
Anggota 2	-
URL Github	https://github.com/SantiLaelatul/UAS-DWH

Informasi Umum Proyek

Judul	Optimasi ETL Pipeline pada Data Warehouse untuk Analisis HIV/AIDS dan Kesehatan Reproduksi Global Berbasis OLAP
Topik	Sosial/Kesehatan
Revisi?	Ya / Tidak

Deskripsi Rumusan masalah	Kesehatan global merupakan salah satu aspek penting yang perlu dipantau secara berkala, terutama terkait penyebaran HIV/AIDS dan kondisi kesehatan reproduksi pada berbagai negara. Informasi kesehatan tersebut digunakan sebagai pendukung evaluasi dan pengambilan kebijakan kesehatan di tingkat internasional. Namun, banyaknya jumlah negara, indikator kesehatan, dan periode waktu menyebabkan proses pengolahan data menjadi cukup kompleks. Permasalahan utama terletak pada sulitnya melakukan integrasi dan analisis data kesehatan global secara cepat dan terstruktur. Dataset kesehatan memiliki karakteristik multidimensi, time-series, serta mengandung missing value dan format data yang belum seragam. Kondisi tersebut menyebabkan proses analisis manual menjadi kurang efisien, terutama ketika ingin melakukan perbandingan antar negara maupun analisis perkembangan indikator kesehatan dari tahun ke tahun. Selain itu, proses eksplorasi data kesehatan global membutuhkan mekanisme analisis yang mampu mendukung query multidimensi dan agregasi data dalam jumlah besar. Tantangan lainnya adalah bagaimana melakukan transformasi data mentah menjadi struktur yang sesuai untuk kebutuhan OLAP sehingga insight dapat diperoleh dengan lebih mudah dan interaktif. Maka dari itu, diperlukan penerapan Data Warehouse dengan proses ETL dan OLAP untuk mengintegrasikan, menyimpan, serta menyajikan data kesehatan global secara lebih terorganisasi dan optimal.
Target insight yang ingin dicapai	Insight yang ingin diperoleh melalui proses Data Staging dan Data Presentation menggunakan mekanisme CUBE query yaitu : 1. Mengetahui tren perkembangan HIV/AIDS global pada periode 2020-2024 2. Menganalisis perkembangan indikator kesehatan reproduksi di berbagai negara 3. Membandingkan kondisi kesehatan antar negara berdasarkan indikator kesehatan tertentu 4. Mengidentifikasi negara yang mengalami peningkatan atau penurunan signifikan pada indikator HIV/AIDS maupun kesehatan reproduksi 5. Melakukan analisis multidimensi berdasarkan dimensi waktu, negara, dan indikator kesehatan

	6. Menampilkan hasil analisis dalam bentuk visualisasi OLAP interaktif menggunakan Atoti.
Referensi penelitian	https://doi.org/10.1016/j.datak.2021.101948 https://doi.org/10.2196/18579 https://doi.org/10.25126/jtiik.2021854232

Informasi Detil Dataset

Sumber dataset	<i>Dataset yang digunakan dalam proyek ini berasal dari World Bank Health Nutrition and Population Statistics yang diakses melalui : https://databank.worldbank.org/source/health-nutrition-and-population-statistics. Proses akuisisi data dilakukan dengan memilih seluruh negara yang tersedia, indikator pada kategori HIV/AIDS dan reproductive health, serta rentang waktu tahun 2020–2024. Dataset diunduh dalam format Excel (.xlsx) dan ZIP (.csv). File Excel digunakan untuk proses observasi dan eksplorasi awal dataset karena memiliki struktur sheet Data dan Series-Metadata dalam satu file, sedangkan file ZIP yang berisi Data.csv dan Series - Metadata.csv digunakan untuk mendukung proses ETL, integrasi database, dan pembangunan Data Warehouse.</i>
Deskripsi umum dataset / datadump	<i>Dataset berisi berbagai indikator kesehatan global yang berkaitan dengan HIV/AIDS dan kesehatan reproduksi dari berbagai negara di dunia. Data utama pada Data memiliki atribut berupa Series Name, Series Code, Country Name, Country Code, serta data tahunan dari tahun 2020 hingga 2024. Selain itu, dataset juga dilengkapi dengan Series-Metadata yang berisi informasi tambahan terkait indikator kesehatan seperti Indicator Name, Short Definition, Long Definition, Source, Topic, Aggregation Method, dan Periodicity. Metadata tersebut digunakan untuk membantu proses identifikasi dan integrasi indikator pada pembangunan Data Warehouse. Dataset memiliki struktur time-series karena memuat data tahunan selama periode 2020–2024 serta bersifat multidimensi karena mencakup banyak negara dan indikator kesehatan.</i>
Aspek khusus dari dataset	<i>Berdasarkan hasil observasi awal, dataset memiliki ukuran sebesar 14.901 baris dan 9 kolom. Dataset terdiri dari data indikator kesehatan global terkait HIV/AIDS dan reproductive health dari berbagai negara dengan rentang waktu tahun 2020–2024. Hasil analisis menunjukkan bahwa dataset memiliki tingkat sparsity sebesar 40.19%, sehingga dapat dikategorikan cukup sparse. Kondisi ini disebabkan oleh banyaknya missing value pada beberapa indikator kesehatan dan negara tertentu, terutama pada tahun terbaru. Hal tersebut terlihat dari jumlah data valid (count) yang terus menurun dari tahun 2020 hingga 2024. Selain itu, distribusi data antar negara dan indikator kesehatan cenderung tidak merata. Berdasarkan statistik deskriptif, nilai maksimum pada masing-masing tahun mencapai puluhan juta, sedangkan nilai median berada pada kisaran sekitar 50–60. Perbedaan yang sangat besar antara nilai median dan maksimum menunjukkan bahwa distribusi data bersifat right-skewed atau tidak normal. Visualisasi boxplot juga menunjukkan adanya outlier pada beberapa indikator kesehatan dengan nilai yang jauh lebih tinggi dibanding data lainnya. Outlier tersebut berasal dari negara dengan jumlah populasi, kasus HIV/AIDS, atau indikator kesehatan tertentu yang sangat tinggi dibanding negara lain. Dataset masih berbentuk wide format dengan kolom tahunan terpisah (2020 [YR2020] hingga 2024 [YR2024]) sehingga memerlukan transformasi menjadi long format untuk mendukung proses ETL, dimensional modeling, dan analisis OLAP multidimensi..</i>

Rencana Data Staging

Gambaran umum proses ekstraksi	Tahap ekstraksi dilakukan menggunakan Python dan library pandas untuk membaca data dari file Excel ke dalam environment analisis. Tahap ini dilakukan identifikasi atribut utama seperti Series Name, Series Code, Country Name, Country Code, serta data tahunan dari tahun 2020 hingga 2024. Selain itu, proses ekstraksi mencakup pengambilan metadata indikator dari Series-Metadata yang berisi informasi tambahan seperti Indicator Name, Short Definition, Topic, Source, dan Aggregation Method. Metadata tersebut nantinya digunakan untuk melengkapi informasi pada dimension table indikator di Data Warehouse.
Gambaran umum proses transformasi	Tahap transformasi dilakukan untuk membersihkan, menyeragamkan, mempersiapkan data agar sesuai dengan kebutuhan dimensional modeling dan analisis OLAP. Transformasi yang akan dilakukan meliputi: 1. Penanganan missing value serta penyesuaian tipe data numerik. 2. Mengubah struktur dataset menjadi wide format menjadi long format menggunakan proses unpivot atau melt sehingga atribut tahun dapat direpresentasikan sebagai dimensi waktu. 3. Standarisasi nama atribut dan tipe data untuk memastikan konsistensi integrasi data pada proses ETL. 4. Menghapus data duplikat dan melakukan validasi terhadap atribut negara, indikator serta periode waktu. 5. Integrasi data utama dengan metadata untuk memperkaya informasi analisis pada dimensional table. 6. Pembuatan surrogate key pada tabel dimensi untuk meningkatkan efisiensi proses query dan OLAP. 7. Pemisahan data ke dalam fact table dan dimension table sesuai pendekatan star schema. Tahap transformasi tersebut bertujuan untuk mendukung karakteristik utama data warehouse, yaitu integrasi data, analisis historis dan efisiensi query multidimensi.
Gambaran umum Proses load	Tahap load dilakukan dengan memuat data hasil transformasi ke PostgreSQL sebagai repositori utama Data Warehouse. Proses load dilakukan melalui beberapa tahapan utama, yaitu: 1. Memasukkan data mentah ke staging table sebagai tempat penyimpanan sementara hasil ekstraksi. 2. Memuat data dimensi ke: • Tabel dimensi negara • Tabel dimensi indikator • Tabel dimensi waktu 3. Memuat data indikator kesehatan ke dalam fact table sebagai pusat analisis OLAP. 4. Membuat relasi antar tabel menggunakan foreign key untuk menjaga integritas data. 5. Mengimplementasikan index pada atribut penting untuk meningkatkan performa query. 6. Membuat materialized view sebagai optimasi agregasi data pada proses OLAP. 7. Menerapkan partition berdasarkan tahun untuk mendukung pengolahan data historis yang lebih efisien. Data yang telah di muat kemudian digunakan untuk proses pembentukan Data Mart dan visualisasi dashboard OLAP menggunakan atoti.

Rencana Data Presentation

Subject focus	Subject utama pada proses OLAP adalah analisis kesehatan global terkait HIV/AIDS dan kesehatan reproduksi berdasarkan indikator kesehatan dari berbagai negara di dunia. Analisis akan difokuskan pada perkembangan indikator kesehatan tiap tahun, perbandingan kondisi kesehatan tiap negara, dan identifikasi kesehatan global berdasarkan dimensi waktu dan indikator tertentu. Pendekatan OLAP digunakan untuk mendukung eksplorasi data multidimensi secara interaktif dan cepat.																								
Star schema	Struktur Data Warehouse pada proyek ini dirancang menggunakan pendekatan star schema untuk mendukung proses OLAP dan analisis multidimensi terhadap data kesehatan global terkait HIV/AIDS dan reproductive health. Star schema terdiri dari satu tabel fakta sebagai pusat penyimpanan data numerik dan beberapa tabel dimensi sebagai pendukung analisis berdasarkan berbagai perspektif. 1. Fact Table (fact_health) Tabel fakta digunakan untuk menyimpan nilai utama indikator kesehatan yang akan dianalisis pada proses OLAP. <table border="1"> <thead> <tr> <th>Atribut</th><th>Keterangan</th></tr> </thead> <tbody> <tr> <td>fact_id</td><td>Primary key fact table</td></tr> <tr> <td>country_id</td><td>Foreign key ke dimensi negara</td></tr> <tr> <td>indicator_id</td><td>Foreign key ke dimensi indikator</td></tr> <tr> <td>time_id</td><td>Foreign key ke dimensi waktu</td></tr> <tr> <td>health_value</td><td>Nilai indikator kesehatan</td></tr> </tbody> </table> Measures utama dalam tabel fakta adalah health_value yang akan digunakan dalam proses agregasi data, perhitungan rata-rata, analisis tren dan perbandingan antar negara maupun periode waktu. Tabel fakta dipilih sebagai pusat OLAP karena menyimpan data numerik utama yang menjadi objek analisis multidimensi. 2. Dimension Table a. dim_counrty Tabel dim_country digunakan untuk menyimpan informasi geografis setiap negara yang terdapat pada dataset. <table border="1"> <thead> <tr> <th>Atribut</th><th>Keterangan</th></tr> </thead> <tbody> <tr> <td>country_id</td><td>Primary key</td></tr> <tr> <td>country_name</td><td>Nama negara</td></tr> <tr> <td>country_code</td><td>Kode negara</td></tr> <tr> <td>region</td><td>Kawasan negara</td></tr> <tr> <td>income_group</td><td>Kelompok ekonomi negara</td></tr> </tbody> </table> Tabel dim_country berperan sebagai dimension geografis yang digunakan untuk membandingkan kondisi kesehatan antar negara, melakukan analisis berdasarkan region dan mengelompokkan negara berdasarkan income group. Pada dimensi ini ditetapkan hierarchy "Region -> Country" yang memungkinkan pengguna melakukan proses drill-down dari level kawasan ke	Atribut	Keterangan	fact_id	Primary key fact table	country_id	Foreign key ke dimensi negara	indicator_id	Foreign key ke dimensi indikator	time_id	Foreign key ke dimensi waktu	health_value	Nilai indikator kesehatan	Atribut	Keterangan	country_id	Primary key	country_name	Nama negara	country_code	Kode negara	region	Kawasan negara	income_group	Kelompok ekonomi negara
Atribut	Keterangan																								
fact_id	Primary key fact table																								
country_id	Foreign key ke dimensi negara																								
indicator_id	Foreign key ke dimensi indikator																								
time_id	Foreign key ke dimensi waktu																								
health_value	Nilai indikator kesehatan																								
Atribut	Keterangan																								
country_id	Primary key																								
country_name	Nama negara																								
country_code	Kode negara																								
region	Kawasan negara																								
income_group	Kelompok ekonomi negara																								

	negara tertentu maupun roll-up dari negara ke level region sehingga eksplorasi data dapat dilakukan secara lebih fleksibel. b. <i>dim_indicator</i> Tabel <i>dim_indicator</i> digunakan untuk menyimpan informasi terkait indikator kesehatan yang akan di analisis. <table border="1"> <thead> <tr> <th><i>Atribut</i></th><th><i>Keterangan</i></th></tr> </thead> <tbody> <tr> <td><i>indicator_id</i></td><td>Primary key</td></tr> <tr> <td><i>indicator_name</i></td><td>Nama indikator kesehatan</td></tr> <tr> <td><i>series_code</i></td><td>Kode indikator</td></tr> <tr> <td><i>topic</i></td><td>Topik indikator</td></tr> <tr> <td><i>source</i></td><td>Sumber data</td></tr> <tr> <td><i>aggregation_method</i></td><td>Metode agregasi</td></tr> </tbody> </table> Dimensi indikator berperan dalam membedakan jenis indikator kesehatan yang dianalisis sehingga pengguna dapat melakukan analisis berdasarkan kategori kesehatan tertentu. Pada dimensi ini diterapkan hierarchy “Topic -> Indicator” yang mendukung pengelompokkan indikator kesehatan berdasarkan topik tertentu seperti HIV/AIDS atau reproductive health sehingga proses analisis menjadi lebih terstruktur. c. <i>dim_time</i> Tabel <i>dim_time</i> digunakan untuk menyimpan informasi periode waktu pada dataset kesehatan global. <table border="1"> <thead> <tr> <th><i>Atribut</i></th><th><i>Keterangan</i></th></tr> </thead> <tbody> <tr> <td><i>time_id</i></td><td>Primary key</td></tr> <tr> <td><i>year</i></td><td>Tahun</td></tr> <tr> <td><i>decade</i></td><td>Dekade</td></tr> </tbody> </table> Dimensi waktu mendukung analisis historis dan time-series sehingga pengguna dapat melihat perkembangan indikator kesehatan dari tahun ke tahun. Pada dimensi waktu diterapkan hierarchy “Decade -> Year”, hierarchy tersebut memungkinkan proses roll-up data tahunan menjadi dekade maupun drill-down dari dekade ke tahun tertentu sehingga analisis tren historis dapat dilakukan dengan lebih mudah. Seluruh tabel dimensi dihubungkan dengan tabel fakta melalui foreign key sehingga membentuk struktur star schema. Struktur ini mendukung proses OLAP seperti slice, dice, drill-down, roll-up, dan pivot analysis secara lebih efisien. Dengan pendekatan star schema, proses analisis kesehatan global dapat dilakukan secara interaktif dan multidimensi menggunakan Atoti sebagai platform visualisasi OLAP.	<i>Atribut</i>	<i>Keterangan</i>	<i>indicator_id</i>	Primary key	<i>indicator_name</i>	Nama indikator kesehatan	<i>series_code</i>	Kode indikator	<i>topic</i>	Topik indikator	<i>source</i>	Sumber data	<i>aggregation_method</i>	Metode agregasi	<i>Atribut</i>	<i>Keterangan</i>	<i>time_id</i>	Primary key	<i>year</i>	Tahun	<i>decade</i>	Dekade
<i>Atribut</i>	<i>Keterangan</i>																						
<i>indicator_id</i>	Primary key																						
<i>indicator_name</i>	Nama indikator kesehatan																						
<i>series_code</i>	Kode indikator																						
<i>topic</i>	Topik indikator																						
<i>source</i>	Sumber data																						
<i>aggregation_method</i>	Metode agregasi																						
<i>Atribut</i>	<i>Keterangan</i>																						
<i>time_id</i>	Primary key																						
<i>year</i>	Tahun																						
<i>decade</i>	Dekade																						
Target hasil OLAP	Target hasil OLAP yang ingin dicapai meliputi: 1. Menampilkan tren perkembangan HIV/AIDS dan Reproductive Health secara global. 2. Membandingkan indikator kesehatan antar negara dan region. 3. Mengidentifikasi negara dengan perubahan indikator kesehatan signifikan. 4. Mendukung proses drill-down, roll-up, slice, dan dice pada cube OLAP.																						

	5. Menyajikan dashboard dan visualisasi interaktif menggunakan atoti berupa: • <i>Line chart</i> • <i>Bar chart</i> • <i>Pivot chart</i> • <i>Dashboard OLAP multidimensi</i>
--	--